

Universidade Federal de Uberlândia
Faculdade de Computação
Programa de Pós-Graduação em Computação
Disciplina: Redes Complexas
Professor: Gilberto Medeiros Nakamura
Aluno: **Amaury Walbert de Carvalho**

Relatório do Projeto de Redes Complexas

Detecção de Domínios Funcionais

1. Introdução

Este relatório apresenta os resultados do desenvolvimento do projeto de Redes Complexas que permitiu consolidar os conceitos de modelagem de redes, medidas de centralidade e detecção de comunidades, aplicando-os à análise estrutural de proteínas.

Proteínas são macromoléculas biológicas cuja estrutura tridimensional está diretamente relacionada às suas funções. A complexidade das interações entre aminoácidos faz com que abordagens tradicionais de análise estrutural nem sempre sejam suficientes para identificar padrões organizacionais relevantes. Nesse contexto, a Teoria das Redes Complexas tem se mostrado uma ferramenta promissora para representar e investigar sistemas biológicos, permitindo modelar proteínas como grafos e aplicar métricas topológicas para estudar sua organização estrutural e funcional.

Neste projeto foi utilizada a estrutura 6B1T, correspondente ao adenovírus humano tipo 5 (Human Adenovirus Type 5). Essa estrutura apresenta elevada complexidade, sendo composta por múltiplas proteínas estruturais, incluindo Hexon, Penton e proteínas acessórias associadas ao capsídeo viral. A disponibilidade de anotações biológicas detalhadas para essas proteínas torna a 6B1T um alvo adequado para a validação de métodos de detecção de comunidades em redes biológicas.

A proteína foi modelada como uma rede não direcionada e ponderada, na qual os nós representam resíduos de aminoácidos e as arestas representam relações estruturais e biológicas entre esses resíduos. A partir dessa representação foram realizadas análises topológicas e aplicados algoritmos de detecção de comunidades com o objetivo de identificar agrupamentos que possam corresponder a unidades estruturais ou funcionais conhecidas da proteína.

O objetivo do projeto é modelar a proteína 6B1T como uma rede complexa, caracterizar sua estrutura topológica, aplicar diferentes métodos de detecção de comunidades e comparar os

agrupamentos obtidos com as anotações biológicas disponibilizadas pelo RCSB Protein Data Bank. Dessa forma, busca-se avaliar a capacidade das técnicas de redes complexas em recuperar informações estruturais e funcionais presentes na organização do capsídeo viral.

2. Preparação dos Dados

2.1 Obtenção dos Dados

As estruturas proteicas utilizadas neste trabalho foram obtidas a partir do Protein Data Bank (PDB), principal repositório internacional de estruturas tridimensionais de macromoléculas biológicas. O alvo principal da análise foi a proteína 6B1T, disponível no Protein Data Bank (PDB) (<https://www.rcsb.org/structure/6B1T>), correspondente à estrutura do adenovírus humano tipo 5 (Human Adenovirus Type 5).

2.2 Estratégia de Validação

Para a validação do pipeline computacional do projeto foi utilizada a estrutura 1A3N, também disponível no PDB (<https://www.rcsb.org/structure/1A3N>). Essa etapa permitiu testar e ajustar os procedimentos de extração de dados, modelagem da rede e detecção de comunidades antes da execução sobre a proteína principal.

Nessa etapa foram avaliadas as rotinas de leitura do arquivo PDB, extração dos resíduos, construção da rede, cálculo das métricas topológicas e execução dos algoritmos de detecção de comunidades.

2.3 Análise Topológica e Validação Biológica dos Diferentes Limiares

Com o objetivo de definir o parâmetro de distância mais adequado para a construção da rede, foram realizados experimentos utilizando os limiares de **4 Å**, **6 Å**, **8 Å** e **10 Å** sobre a proteína de teste 1A3N. Em todos os casos foi empregada a mesma estratégia de modelagem da rede, baseada em contatos espaciais ponderados pela afinidade bioquímica e complementados por conexões entre cadeias homólogas, detalhada na seção 3.

Com o limiar de 4 Å, a rede ficou desconexa. Para os demais limiares testados, todos preservaram a conectividade global da proteína, permitindo que a escolha fosse realizada com base principalmente na qualidade da organização modular observada.

Observou-se inicialmente que o aumento do limiar produziu redes progressivamente mais densas. O número de arestas aumentou de 2.051 para 5.547, elevando o grau médio de 7,17 para 19,40 e reduzindo o comprimento médio dos caminhos de 7,40 para 3,75. Consequentemente, o diâmetro da rede também diminuiu, indicando maior integração estrutural entre os resíduos.

Essa tendência também foi refletida nas medidas de centralidade dos vértices. À medida que o limiar aumentou, houve crescimento do grau, do coeficiente de agrupamento (*clustering coefficient*), da centralidade de proximidade (*closeness*) e da centralidade de autovetor

(*eigenvector centrality*), indicando que os resíduos passaram a possuir maior influência local e global na rede. Em contrapartida, observou-se redução dos valores máximos de centralidade de intermediação (*betweenness centrality*), evidenciando que o aumento do número de conexões reduziu a dependência de vértices específicos para a comunicação entre diferentes regiões da proteína. O PageRank permaneceu praticamente estável entre os três experimentos, indicando que a importância relativa dos resíduos foi pouco afetada pelo aumento da conectividade.

Apesar dessa evolução das propriedades topológicas, a capacidade de recuperação da organização biológica apresentou comportamento distinto. A bipartição espectral baseada no vetor de Fiedler recuperou corretamente a separação entre as subunidades α e β para os três limiares avaliados, demonstrando que a estrutura global da proteína permaneceu preservada independentemente do parâmetro utilizado.

Os algoritmos de detecção de comunidades, entretanto, apresentaram sensibilidades diferentes ao aumento da conectividade. O Louvain manteve um número semelhante de comunidades nos três experimentos, porém apresentou redução gradual da modularidade (0,822; 0,745 e 0,696 para 6 Å, 8 Å e 10 Å, respectivamente), acompanhada de pequenas reduções nos índices NMI e ARI. Esse comportamento indica que o aumento do número de conexões reduz progressivamente o contraste entre os módulos estruturais da rede.

O Infomap apresentou comportamento distinto. Enquanto o limiar de 6 Å produziu sete comunidades altamente puras, o aumento para 8 Å reduziu a partição para apenas três comunidades, mantendo elevada concordância com as anotações biológicas. Entretanto, ao utilizar 10 Å, observou-se redução significativa dos índices de concordância e da pureza das comunidades, indicando que o excesso de contatos passou a conectar regiões pertencentes a diferentes subunidades estruturais. A Tabela 01 resume os principais resultados obtidos para a proteína 1A3N.

Tabela 01: Métricas para a diferentes limiares de construção da rede da proteína 1A3N

Métrica	6 Å	8 Å	10 Å
Arestas	2.051	3.114	5.547
Grau médio	7,17	10,89	19,40
Densidade	0,0126	0,0191	0,0340
Comprimento médio	7,40	5,12	3,75
Diâmetro	16	11	8
Modularidade (Louvain)	0,822	0,745	0,696
Comunidades (Louvain)	13	12	12
Comunidades (Infomap)	7	3	3
NMI (Louvain)	0,432	0,400	0,369
ARI (Louvain)	0,166	0,164	0,146
Purity (Louvain)	1,000	0,965	0,955
NMI (Infomap)	0,552	0,597	0,310
ARI (Infomap)	0,356	0,597	0,205
Purity (Infomap)	1,000	0,948	0,731

2.4 Escolha do Limiar

Os experimentos mostram que a escolha do limiar envolve um compromisso entre preservação estrutural e conectividade da rede. O limiar de **6 Å** apresentou os melhores resultados quantitativos para o algoritmo Louvain, além de Pureza igual a 1,0 para Louvain e Infomap, evidenciando excelente preservação das unidades biológicas conhecidas. Por outro lado, produziu uma rede mais esparsa e uma maior fragmentação das comunidades, especialmente no Infomap.

O limiar de **8 Å** apresentou desempenho quantitativo muito próximo ao obtido em 6 Å para o Louvain e os melhores índices NMI e ARI para o Infomap, além de reduzir significativamente a fragmentação das comunidades e gerar uma rede mais integrada. Já o limiar de **10 Å** tornou a rede excessivamente conectada, reduzindo a modularidade, diminuindo a capacidade de separação das comunidades e degradando os indicadores de validação biológica.

Considerando conjuntamente as propriedades topológicas da rede, a evolução das medidas de centralidade e os resultados obtidos pelos diferentes algoritmos de detecção de comunidades, optou-se pela utilização do limiar **de 8 Å** nos experimentos com a proteína 6B1T. Embora o limiar de 6 Å tenha apresentado ligeira vantagem em alguns indicadores quantitativos, o valor de 8 Å proporcionou uma rede mais conectada, menos fragmentada e com melhor capacidade de generalização para uma proteína significativamente maior e mais complexa, mantendo elevada concordância com a organização biológica observada na proteína de validação.

3. Modelagem da Rede Complexa

3.1 Modelagem da Proteína de Testes - 1A3N

A definição da modelagem da rede foi realizada de forma incremental utilizando a proteína 1A3N como estudo de caso. O objetivo foi avaliar diferentes estratégias de construção das arestas e selecionar aquela que melhor representasse a organização estrutural e biológica da proteína antes da aplicação na proteína alvo 6B1T.

A estrutura 1A3N correspondente à desoxi-hemoglobina humana (Deoxy Human Hemoglobin). A escolha dessa estrutura deve-se ao seu menor porte e à sua organização estrutural bem caracterizada, tornando-a adequada para validar o pipeline de construção da rede, análise topológica e detecção de comunidades.

A proteína 1A3N é um tetrâmero formado por duas cadeias α (A e C) e duas cadeias β (B e D), totalizando quatro cadeias proteicas organizadas em dois grupos estruturais distintos. Essa organização fornece uma referência biológica conhecida para avaliar se os algoritmos de detecção de comunidades são capazes de recuperar agrupamentos compatíveis com a estrutura da proteína.

Inicialmente foi utilizada uma Rede de Contatos por Resíduos (Residue Contact Network – RCN), em que cada resíduo foi representado por um nó e uma aresta foi criada entre dois resíduos sempre que a distância entre seus átomos C α fosse inferior ao limiar estabelecido. Nessa primeira abordagem, o peso das arestas foi definido exclusivamente pela proximidade espacial entre os resíduos.

Na segunda etapa, manteve-se a mesma definição de contatos espaciais, porém os pesos passaram a incorporar também a afinidade bioquímica entre os aminoácidos. Embora essa modificação tenha tornado a representação biologicamente mais realista, os ganhos observados na qualidade da detecção de comunidades foram limitados.

Por fim, foi proposta uma modelagem híbrida, combinando proximidade espacial, afinidade bioquímica e homologia entre as cadeias. Para isso, foi construída uma matriz de similaridade entre todas as cadeias da proteína utilizando o algoritmo Longest Common Subsequence (LCS). Cadeias altamente homólogas passaram a receber conexões adicionais entre resíduos equivalentes, permitindo representar explicitamente relações estruturais conservadas que não são capturadas apenas pela geometria da proteína.

A Tabela 02 resume os principais resultados obtidos para as três estratégias de modelagem.

Tabela 02: Resultados da Análise das Estratégias de Modelagem da Rede

Modelagem	Fiedler	Louvain	Infomap
Apenas contatos espaciais	Não separou corretamente α/β	NMI = 0,326	NMI = 0,338
		ARI = 0,117	ARI = 0,276
		Purity = 0,923	Purity = 0,871
Espacial + bioquímica	Resultado semelhante ao modelo espacial	NMI = 0,358	NMI = 0,258
		ARI = 0,140	ARI = 0,171
		Purity = 0,951	Purity = 0,713
Espacial + bioquímica + homologia	Separou corretamente os grupos α e β	NMI = 0,400	NMI = 0,597
		ARI = 0,164	ARI = 0,597
		Purity = 0,965	Purity = 0,948

Observa-se que a inclusão apenas da afinidade bioquímica produziu melhorias discretas no Louvain, mas não trouxe ganhos consistentes para os demais algoritmos. Em contrapartida, a incorporação das informações de homologia entre as cadeias resultou em melhora simultânea nos três métodos avaliados. A partição espectral passou a separar corretamente as duas famílias estruturais (α e β), o Louvain apresentou os maiores valores de NMI, ARI e Purity, e o Infomap obteve um aumento expressivo de concordância com as anotações biológicas.

Esses resultados indicam que a homologia entre cadeias constitui uma informação complementar relevante à proximidade espacial e à afinidade bioquímica, permitindo representar

de forma mais fiel a organização estrutural da proteína. Por esse motivo, a modelagem híbrida foi adotada nas análises realizadas com a proteína 6B1T.

3.2 Modelagem da Proteína Alvo - 6B1T

Após a validação da metodologia na proteína 1A3N, o pipeline foi aplicado à estrutura 6B1T, correspondente ao adenovírus humano tipo 5 (Human Adenovirus 5). Essa estrutura foi determinada por crio-microscopia eletrônica (cryo-EM) com resolução de 3,2 Å, permitindo a identificação em nível atômico não apenas das principais proteínas do capsídeo, mas também das proteínas acessórias VI e VII, anteriormente pouco caracterizadas experimentalmente. A estrutura representa uma versão refinada de modelos anteriores do adenovírus e esclarece a organização das proteínas cimentadoras IIIa, VIII e IX, além de fornecer evidências sobre o mecanismo de coassemblagem entre o capsídeo viral e o genoma.

A estrutura analisada corresponde a um capsídeo viral pseudo-icosaédrico do tipo T = 25, formado principalmente por proteínas Hexon, responsáveis pela maior parte da superfície do capsídeo, e pelas proteínas Penton, localizadas nos vértices da partícula viral. Além dessas proteínas estruturais principais, o modelo inclui as proteínas acessórias IIIa, VIII, IX, VI e VII, que desempenham funções importantes na estabilização do capsídeo, na interação entre os hexons e no empacotamento do DNA viral. A presença simultânea dessas diferentes famílias proteicas torna a estrutura particularmente adequada para estudos de redes complexas e detecção de comunidades, uma vez que fornece uma organização biológica previamente conhecida para validação dos agrupamentos obtidos.

Na estrutura utilizada neste trabalho foram consideradas 25 cadeias proteicas, correspondentes às cadeias A–L (Hexon), M (Penton), N (IIIa), O–P (VIII), Q–T (IX), U, V, X e Y (VI) e W (VII), totalizando 12.544 resíduos modelados como vértices da rede. Essa diversidade estrutural, aliada ao elevado número de resíduos e à repetição de proteínas homólogas distribuídas ao longo do capsídeo, torna a 6B1T um caso de estudo significativamente mais complexo do que a proteína de validação, permitindo avaliar a capacidade da modelagem proposta em recuperar tanto grandes unidades estruturais, como Penton e Hexon, quanto proteínas acessórias e módulos internos do capsídeo viral.

4. Análise Topológica da Rede

Após a construção da rede de resíduos, foi realizada uma análise topológica com o objetivo de caracterizar sua organização estrutural e identificar padrões relevantes associados à arquitetura tridimensional da proteína. Foram investigadas a distribuição de graus e diferentes medidas de centralidade, permitindo avaliar a importância relativa dos resíduos dentro da rede.

4.1 Análise Topológica da Rede

A modelagem da proteína 6B1T resultou em uma rede não direcionada e ponderada composta por 12.544 resíduos (nós) e 127.081 interações (arestas). A rede apresentou grau médio igual a 20,26, indicando que cada resíduo estabelece contato, em média, com


aproximadamente vinte resíduos vizinhos. O grau máximo igual a 31 evidencia a existência de regiões estruturalmente mais conectadas, compatíveis com interfaces entre proteínas e áreas de elevada compactação do capsídeo.

Apesar do elevado número absoluto de conexões, a rede apresentou densidade igual a 0,0016, característica esperada em redes de proteínas de grande porte, nas quais apenas uma pequena fração de todos os pares possíveis de resíduos estabelece contato físico. Essa baixa densidade demonstra que a modelagem preserva a organização espacial da estrutura, evitando a criação de conexões artificiais entre regiões distantes da proteína.

A rede mostrou-se totalmente conectada, permitindo o cálculo do comprimento médio dos caminhos mais curtos, igual a 9,03, e diâmetro igual a 30. Esses valores indicam que, embora o capsídeo seja formado por milhares de resíduos distribuídos em diferentes proteínas, qualquer resíduo pode ser alcançado a partir de outro por um número relativamente pequeno de interações sucessivas. Esse comportamento é compatível com a arquitetura tridimensional altamente integrada do adenovírus, na qual proteínas estruturais e acessórias estabelecem uma extensa rede de contatos locais responsável pela estabilidade do capsídeo.

Figura 01: Rede de resíduos para a proteína 6B1T

6B1T (8.0 Å)
Rede de resíduos



A distribuição dos graus evidencia uma rede heterogênea, composta por grande quantidade de resíduos com conectividade intermediária e um número reduzido de resíduos

altamente conectados. Esses vértices correspondem, provavelmente, a regiões de interface entre proteínas ou a resíduos localizados em domínios estruturais mais compactos.

Foram também calculadas diferentes medidas de centralidade com o objetivo de identificar resíduos estruturalmente relevantes. O coeficiente médio de agrupamento (*clustering coefficient*) foi igual a 0,38, indicando forte tendência à formação de vizinhanças locais densamente conectadas. Esse resultado está de acordo com a organização do capsídeo viral, no qual resíduos pertencentes ao mesmo domínio estrutural compartilham grande parte de seus contatos.


A centralidade de proximidade (*closeness centrality*) apresentou baixa variação entre os resíduos, refletindo a elevada integração da rede e indicando que grande parte dos vértices encontra-se relativamente próxima dos demais quando considerada a topologia da proteína.

Em contraste, a centralidade de intermediação (*betweenness centrality*) apresentou valores elevados apenas para um pequeno conjunto de resíduos, sugerindo que poucos vértices atuam como pontes entre diferentes regiões estruturais. Esses resíduos representam candidatos naturais a interfaces entre domínios ou entre diferentes proteínas do capsídeo.

A centralidade por autovetor (*eigenvector centrality*) mostrou distribuição bastante assimétrica, indicando que apenas uma pequena parcela dos resíduos encontra-se conectada simultaneamente a outros resíduos altamente influentes. Esses vértices tendem a localizar-se em regiões centrais da arquitetura do capsídeo ou em interfaces responsáveis por sua estabilização.


O PageRank apresentou distribuição relativamente homogênea entre os resíduos, sugerindo que a importância estrutural da maioria dos vértices decorre da organização coletiva da rede, e não da presença de poucos resíduos extremamente dominantes.

Figura 02: Métricas de centralidade calculadas na rede da proteína 6B1T



Em conjunto, essas métricas revelam que a proteína 6B1T possui uma organização altamente modular e localmente densa, composta por múltiplos grupos de resíduos fortemente conectados entre si e integrados por um pequeno conjunto de resíduos de intermediação. Essa configuração é consistente com a arquitetura tridimensional esperada do capsídeo do adenovírus, formado por proteínas Hexon repetidas e estabilizado por proteínas acessórias, como Penton, IIIa, VIII, IX, VI e VII, responsáveis pela conexão entre diferentes módulos estruturais.

Figura 03: Principais medidas de centralidade destacadas na rede da proteína 6B1T




5. Detecção de Comunidades

5.1 Bipartição Espectral

Como primeira abordagem para a identificação de comunidades, foi empregada a partição espectral baseada na matriz Laplaciana da rede. Foram calculados os dez menores autovalores da Laplaciana normalizada, apresentados na Figura 04.

Figura 04: Espectro dos dez menores valores da Laplaciana.



O primeiro autovalor é numericamente nulo, como esperado para uma rede conexa, enquanto o segundo autovalor (valor de Fiedler) apresentou magnitude muito pequena, indicando a existência de uma divisão estrutural bem definida na rede. A ausência de grandes lacunas entre os demais autovalores sugere, entretanto, que a proteína apresenta uma organização composta por diversos módulos estruturais, e não apenas por uma única bipartição dominante. A partição obtida pelo vetor de Fiedler dividiu a rede em dois grupos contendo 11.711 e 833 resíduos, respectivamente.

A análise da composição biológica dos grupos revela que a partição espectral isolou praticamente toda a proteína Penton (cadeia M), alocando seus 455 resíduos no mesmo grupo. Além disso, parte significativa das proteínas acessórias IIIa (cadeia N) e VIII (cadeia O) também foi agrupada nesse conjunto, enquanto as proteínas Hexon (cadeias A–L) permaneceram quase integralmente no grupo principal.

Esse comportamento é consistente com a organização estrutural do adenovírus. A proteína Penton ocupa os vértices do capsídeo e apresenta uma conectividade distinta daquela observada para os Hexons, que constituem a maior parte da superfície viral e estabelecem numerosos contatos entre si. Como consequência, o vetor de Fiedler identifica inicialmente essa

separação estrutural mais pronunciada, sem, contudo, distinguir individualmente os diferentes módulos formados pelas proteínas Hexon.

Observa-se ainda que algumas proteínas acessórias apresentaram comportamento intermediário. A cadeia N (IIIa) foi predominantemente agrupada com o Penton (261 de 288 resíduos), enquanto a cadeia O (VIII) apresentou divisão parcial entre os dois grupos. Já as proteínas IX, VI e VII permaneceram quase integralmente no grupo majoritário, indicando maior integração estrutural com o conjunto dos Hexons.

Tabela 03: Matriz de contingência da bipartição espectral e as cadeias da proteína

spectral_group	0	1	spectral_group	0	1
chain			chain		
A	5	903	N	261	27
B	42	868	O	19	161
C	7	903	P	0	180
D	4	902	Q	0	119
E	5	909	R	0	93
F	2	908	S	0	86
G	3	906	T	0	88
H	8	905	U	0	29
I	7	903	V	0	29
J	2	911	W	0	11
K	5	905	X	0	33
L	8	904	Y	0	28
M	455	0	-	-	-

Esses resultados evidenciam uma limitação inerente à partição espectral baseada apenas no vetor de Fiedler. Por produzir exclusivamente uma bipartição da rede, o método consegue identificar apenas a principal divisão estrutural da proteína, mas não recupera sua organização modular completa. Considerando que a estrutura 6B1T é composta por múltiplas famílias de proteínas e diversas cópias homólogas distribuídas pelo capsídeo, torna-se necessária a utilização de algoritmos capazes de detectar um número arbitrário de comunidades. Por essa razão, nas etapas seguintes do trabalho foram empregados os algoritmos Louvain e Infomap, que permitem identificar uma estrutura hierárquica mais compatível com a organização biológica do adenovírus.

5.2 Algoritmo de Louvain

Após a análise da bipartição espectral, foi aplicado o algoritmo de Louvain para identificação automática de comunidades. O algoritmo detectou 19 comunidades, com modularidade igual a 0,7782, indicando uma forte estrutura modular da rede. Esse valor evidencia que os resíduos estão organizados em grupos densamente conectados internamente e relativamente pouco conectados entre si.

A distribuição do tamanho das comunidades mostrou forte heterogeneidade. As maiores comunidades corresponderam principalmente às proteínas Hexon, contendo entre aproximadamente 900 e 1.500 resíduos, enquanto as menores comunidades representaram proteínas acessórias de dimensões reduzidas, como VI, VII e IX.

Para avaliar a correspondência entre as comunidades detectadas e as anotações estruturais disponíveis no RCSB, foram calculadas as métricas NMI, ARI e Purity.

Tabela 04: Métricas do Algoritmo de Louvain

Métrica	Valor
Modularity	0,7782
NMI	0,2929
ARI	0,0426
Purity	0,9639

A elevada Purity (96,39%) indica que praticamente todas as comunidades são compostas predominantemente por resíduos pertencentes a uma mesma família proteica. Em contraste, os valores reduzidos de NMI e ARI refletem o fato de que o algoritmo não recupera exatamente as categorias biológicas anotadas, mas subdivide algumas delas em múltiplos módulos estruturais.

Esse comportamento é esperado para proteínas virais de grande porte. Enquanto as anotações do RCSB descrevem famílias de proteínas, o Louvain identifica comunidades de acordo com a conectividade da rede, podendo dividir uma mesma proteína em diferentes módulos quando estes apresentam organização topológica própria. A Figura 05 mostra claramente essa característica.

Figura 05: Matriz de contingência das famílias proteicas e as comunidades detectadas pelo Louvain

louvain	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
truth																			
Hexon	1299	658	1482	1165	0	943	937	312	1166	1082	541	244	0	0	5	0	0	0	1091
Illa	0	0	0	0	0	0	0	0	0	0	0	0	0	132	156	0	0	0	0
IX	0	0	0	5	42	0	13	68	0	38	0	0	0	0	0	0	42	178	0
Penton	0	0	0	0	0	0	0	6	0	0	0	0	436	13	0	0	0	0	0
VI	0	15	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	104
VII	0	0	0	0	0	6	0	0	0	0	0	0	0	0	0	0	0	0	5
VIII	0	0	0	0	0	0	0	0	0	0	0	0	0	0	241	100	0	0	19

Observa-se que as proteínas acessórias foram recuperadas quase integralmente em comunidades específicas. A proteína Penton, por exemplo, foi praticamente isolada na comunidade 12 (436 resíduos), enquanto a proteína IIIa concentrou-se principalmente nas comunidades 13 e 14. De forma semelhante, a proteína VIII foi distribuída predominantemente entre as comunidades 14 e 15.

A principal exceção corresponde aos Hexons, responsáveis pela maior parte do capsídeo viral. Em vez de formar uma única comunidade, os resíduos Hexon foram distribuídos entre diversas comunidades de grande porte, refletindo sua elevada conectividade e a repetição estrutural característica dessa família proteica.

Esse resultado indica que o algoritmo foi capaz de distinguir adequadamente proteínas estruturalmente distintas, mas também identificou subdivisões internas nos Hexons, compatíveis com sua organização modular. A Figura 06 fornece uma interpretação adicional dos resultados.

Figura 06: Matriz de contingência das cadeias da proteína e as comunidades detectadas pelo Louvain

community	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
chain																			
A	106	50	129	101	0	93	79	31	94	79	45	21	0	0	0	0	0	0	80
B	107	58	121	107	0	74	70	18	102	95	46	21	0	0	0	0	0	0	91
C	103	51	126	111	0	74	90	30	93	73	46	21	0	0	0	0	0	0	92
D	96	51	133	86	0	106	71	34	95	85	50	19	0	0	0	0	0	0	80
E	100	55	124	86	0	79	81	26	102	101	44	24	0	0	0	0	0	0	92
F	116	63	122	95	0	59	80	27	89	95	38	21	0	0	0	0	0	0	105
G	108	52	120	94	0	76	102	21	91	98	43	21	0	0	0	0	0	0	83
H	124	52	111	100	0	83	70	29	94	83	46	21	0	0	0	0	0	0	100
I	103	60	136	92	0	68	73	25	102	87	50	12	0	0	0	0	0	0	102
J	109	54	120	97	0	74	77	21	106	105	44	21	0	0	0	0	0	0	85
K	114	58	122	96	0	68	67	28	101	84	47	21	0	0	5	0	0	0	99
L	113	54	118	100	0	89	77	22	97	97	42	21	0	0	0	0	0	0	82
M	0	0	0	0	0	0	0	6	0	0	0	0	436	13	0	0	0	0	0
N	0	0	0	0	0	0	0	0	0	0	0	0	0	132	156	0	0	0	0
O	0	0	0	0	0	0	0	0	0	0	0	0	0	0	120	51	0	0	9
P	0	0	0	0	0	0	0	0	0	0	0	0	0	0	121	49	0	0	10
Q	0	0	0	0	0	0	9	0	0	10	0	0	0	0	0	0	42	58	0
R	0	0	0	5	42	0	0	0	0	4	0	0	0	0	0	0	0	42	0
S	0	0	0	0	0	0	0	36	0	12	0	0	0	0	0	0	0	38	0
T	0	0	0	0	0	0	4	32	0	12	0	0	0	0	0	0	0	40	0
U	0	5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	24
V	0	5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	24
W	0	0	0	0	0	6	0	0	0	0	0	0	0	0	0	0	0	0	5
X	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	33
Y	0	5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	23

As doze cadeias Hexon (A–L) apresentam um comportamento praticamente idêntico. Cada cadeia distribui seus resíduos entre as mesmas comunidades e em proporções muito semelhantes. Por exemplo, todas as cadeias possuem aproximadamente 120 resíduos na comunidade 2, cerca de 100 resíduos nas comunidades 0, 3, 8 e 9, além de pequenas frações distribuídas nas demais comunidades.

Esse padrão demonstra que o Louvain não distingue as diferentes cópias do Hexon, mas identifica regiões estruturalmente equivalentes presentes em todas elas. Como essas cadeias são altamente homólogas e ocupam posições semelhantes na arquitetura do capsídeo, seus resíduos apresentam padrões de conectividade praticamente indistinguíveis, sendo naturalmente agrupados nas mesmas comunidades.

Em contrapartida, proteínas estruturalmente distintas apresentam comunidades praticamente exclusivas. A cadeia M (Penton), por exemplo, concentra quase todos os seus resíduos em uma única comunidade, enquanto as proteínas IIIa, VIII e IX também apresentam

comunidades dominantes bem definidas. Os resultados indicados na Tabela 05 reforçam essa interpretação.

Tabela 05: Resultados do cálculo da pureza individual das cadeias para o Louvain

Cadeia	Pureza	Cadeia	Pureza
A	0.142070	N	0.541667
B	0.132967	O	0.666667
C	0.138462	P	0.672222
D	0.146799	Q	0.487395
E	0.135667	R	0.451613
F	0.134066	S	0.441860
G	0.132013	T	0.454545
H	0.135816	U	0.827586
I	0.149451	V	0.827586
J	0.131435	W	0.545455
K	0.134066	X	1.000000
L	0.129386	Y	0.821429
M	0.958242	—	—

As maiores purezas foram observadas para proteínas estruturalmente independentes, como Penton (95,8%) e as pequenas proteínas acessórias X, U, V e Y, indicando que seus resíduos permaneceram praticamente concentrados em uma única comunidade.

Por outro lado, todas as cadeias Hexon apresentaram valores próximos de 0,13–0,15, resultado que inicialmente poderia sugerir baixo desempenho do algoritmo. Entretanto, essa interpretação seria incorreta. Esses valores refletem apenas que cada cadeia Hexon foi subdividida em diversos módulos, enquanto as mesmas subdivisões aparecem repetidas em todas as demais cópias homólogas do Hexon. Assim, o Louvain não está separando cadeias, mas identificando módulos estruturais recorrentes dentro da arquitetura do capsídeo.

Em conjunto, esses resultados indicam que o algoritmo Louvain recuperou com elevada fidelidade a organização modular da proteína 6B1T. Embora não reproduza exatamente as anotações biológicas utilizadas como referência, suas comunidades apresentam forte coerência estrutural, elevada modularidade e alta pureza, evidenciando que a organização topológica da rede está intimamente relacionada à arquitetura tridimensional do capsídeo viral. Essa análise também explica os valores relativamente baixos de NMI e ARI: essas métricas penalizam a subdivisão das famílias Hexon, apesar de essa subdivisão representar uma característica estrutural real da rede e não um erro do algoritmo.

5.3 Algoritmo Infomap

Como terceira abordagem para detecção de comunidades, foi empregado o algoritmo Infomap, baseado na minimização da descrição de caminhadas aleatórias sobre a rede.

Diferentemente do Louvain, o algoritmo identificou apenas **duas comunidades**, contendo **11.966** e **578** resíduos, respectivamente. A comparação com as anotações biológicas resultou nos seguintes indicadores da Tabela 06.

Tabela 06: Métricas do algoritmo Infomap

Métrica	Valor
NMI	0,4425
ARI	0,4703
Purity	0,9072

Observa-se que o Infomap apresentou valores de **NMI** e **ARI** superiores aos obtidos pelo Louvain, indicando maior concordância global com a classificação biológica de referência. Entretanto, a **Purity** foi inferior (90,72%), evidenciando que essa maior concordância decorre principalmente da recuperação de uma divisão estrutural ampla, e não da identificação de módulos biológicos mais específicos. A Figura 07 claramente essa característica.

Figura 07: Matriz de contingência das famílias proteicas e as comunidades detectadas pelo Infomap

infomap	1	2
truth		
Hexon	10925	0
Illa	165	123
IX	386	0
Penton	0	455
VI	119	0
VII	11	0
VIII	360	0

Verifica-se que praticamente todos os resíduos pertencentes aos **Hexons**, bem como às proteínas **IX, VI, VII e VIII**, foram agrupados em uma única comunidade. Em contrapartida, a segunda comunidade foi composta quase exclusivamente pela proteína **Penton**, contendo seus 455 resíduos, além de parte da proteína **Illa**.

Esse resultado demonstra que o Infomap identificou como principal divisão da rede a separação entre o complexo formado pelos Hexons e a região correspondente ao Penton. Do ponto de vista estrutural, essa bipartição é biologicamente plausível, uma vez que o Penton ocupa os vértices do capsídeo e apresenta um padrão de conectividade distinto das proteínas que compõem a superfície viral. A distribuição das comunidades indicada na Figura 08 confirma essa interpretação.

Figura 08: Matriz de contingência das cadeias da proteína e as comunidades detectadas pelo Infomap

community	1	2
chain		
A	908	0
B	910	0
C	910	0
D	906	0
E	914	0
F	910	0
G	909	0
H	913	0
I	910	0
J	913	0
K	910	0
L	912	0
M	0	455
N	165	123
O	180	0
P	180	0
Q	119	0
R	93	0
S	86	0
T	88	0
U	29	0
V	29	0
W	11	0
X	33	0
Y	28	0

As doze cadeias **Hexon (A–L)** permaneceram integralmente na comunidade principal, apresentando pureza de **100%**. O mesmo comportamento foi observado para praticamente todas as proteínas acessórias. A única exceção corresponde à cadeia **N (proteína IIIa)**, cujos resíduos foram divididos entre as duas comunidades, refletindo sua posição intermediária na estrutura do capsídeo e suas interações tanto com o Penton quanto com os Hexons. Os resultados apresentados na Tabela 08 evidenciam a estabilidade dessa solução.

Tabela 08: Resultados do cálculo da pureza individual das cadeias para o Infomap

Cadeia	Pureza	Cadeia	Pureza
A	1.000000	N	0.572917
B	1.000000	O	1.000000
C	1.000000	P	1.000000
D	1.000000	Q	1.000000
E	1.000000	R	1.000000
F	1.000000	S	1.000000
G	1.000000	T	1.000000
H	1.000000	U	1.000000
I	1.000000	V	1.000000
J	1.000000	W	1.000000
K	1.000000	X	1.000000
L	1.000000	Y	1.000000
M	1.000000	—	—

Com exceção da cadeia IIIa, todas as demais cadeias apresentaram pureza igual a 100%, indicando que seus resíduos permaneceram completamente agrupados em uma única comunidade. Apenas a cadeia N apresentou pureza de aproximadamente 57%, consequência de sua divisão entre os dois grupos detectados.

Esse comportamento reforça que o Infomap não buscou identificar módulos internos das proteínas, mas sim a principal divisão funcional existente na rede.

6. Validação Biológica

A validação biológica foi realizada comparando as comunidades detectadas com as famílias de proteínas anotadas para a estrutura 6B1T no RCSB. O objetivo ideal consistia em reproduzir essas famílias, enquanto o requisito mínimo estabelecido no projeto era separar as duas principais unidades estruturais do capsídeo: **Hexon** e **Penton**.

A **partição espectral**, baseada no vetor de Fiedler, identificou corretamente essa divisão principal, isolando praticamente toda a proteína Penton juntamente com parte da proteína IIIa. Entretanto, por produzir apenas uma bipartição, o método não foi capaz de recuperar as demais famílias proteicas presentes na estrutura.

O **Infomap** apresentou comportamento semelhante, detectando apenas duas comunidades. A primeira concentrou praticamente todos os Hexons e proteínas acessórias, enquanto a segunda reuniu quase toda a proteína Penton. Como consequência, obteve os maiores valores de **NMI (0,442)** e **ARI (0,470)** entre os métodos avaliados. Contudo, essa solução representa apenas a principal divisão estrutural da rede, sem identificar sua organização modular interna.

O **Louvain**, por sua vez, detectou **19 comunidades** com elevada **modularidade (0,778)** e **Purity (96,39%)**. Embora tenha apresentado valores menores de NMI e ARI, o algoritmo identificou comunidades específicas para diversas proteínas acessórias e subdividiu os Hexons em módulos recorrentes presentes em todas as cadeias homólogas. As matrizes de contingência mostraram que essas subdivisões são consistentes entre as cadeias A–L, indicando que o algoritmo agrupou regiões estruturalmente equivalentes em vez de simplesmente separar cada cadeia individualmente.

Em conjunto, os três métodos atenderam ao requisito mínimo de distinguir o Penton do restante do capsídeo. Entretanto, o Louvain produziu a representação mais rica da organização topológica da proteína, revelando módulos estruturais compatíveis com a arquitetura repetitiva do capsídeo viral. Esses resultados evidenciam que métricas como NMI e ARI, embora úteis para comparação com as anotações biológicas, tendem a penalizar a subdivisão dos Hexons, mesmo quando essa subdivisão representa uma característica estrutural real da rede. Dessa forma, a análise conjunta das métricas quantitativas e da distribuição das comunidades indica que o Louvain forneceu a descrição mais informativa da organização modular da proteína 6B1T.

7. Conclusão

Este trabalho apresentou a modelagem da proteína 6B1T como uma rede complexa, permitindo aplicar técnicas de análise topológica e detecção de comunidades para investigar sua organização estrutural. Inicialmente, foi utilizada a proteína 1A3N como estudo de caso para validar o pipeline computacional e definir os parâmetros da modelagem, incluindo o limiar de distância e a estratégia de construção das arestas.

Os experimentos mostraram que a combinação de contatos espaciais, afinidade bioquímica entre resíduos e homologia entre cadeias produziu uma representação mais consistente da organização estrutural das proteínas, sendo adotada como modelagem final. A análise da proteína 6B1T resultou em uma rede composta por 12.544 resíduos e 127.081 interações, cuja topologia apresentou baixa densidade, elevada conectividade e organização modular compatível com a arquitetura tridimensional do capsídeo viral.

A análise das medidas de centralidade permitiu identificar resíduos potencialmente importantes para a estabilidade estrutural da proteína, enquanto os algoritmos de detecção de comunidades revelaram diferentes níveis de organização. A bipartição espectral recuperou a principal divisão estrutural da rede, separando o Penton do restante do capsídeo. O Infomap também identificou essa divisão de forma consistente, apresentando elevada concordância com as anotações biológicas. O algoritmo Louvain, por sua vez, produziu a representação mais detalhada da organização modular da proteína, identificando módulos recorrentes nas diferentes cadeias Hexon e comunidades específicas para diversas proteínas acessórias.

Os resultados obtidos demonstram que a modelagem proposta foi capaz de representar adequadamente a organização estrutural da proteína e que a utilização de técnicas de Redes Complexas constitui uma abordagem eficaz para investigar proteínas de grande porte. Além de atender aos objetivos propostos no projeto, o trabalho evidenciou o potencial dessas técnicas

para auxiliar na identificação de domínios estruturais e funcionais em sistemas biológicos complexos.

Declaração de Uso de Inteligência Artificial

Este trabalho utilizou o modelo GPT-5.5 (OpenAI) como ferramenta de apoio para elaboração e organização do código e revisão textual do relatório. Todas as decisões metodológicas, experimentos e validações foram realizadas e verificadas pelo autor.

Repositório do Projeto no GitHub

Todo o material desenvolvido neste projeto foi disponibilizado em um repositório público no GitHub. O repositório contém os códigos-fonte completos em Python, implementados em Jupyter Notebook, incluindo todas as etapas do desenvolvimento do trabalho: preparação dos dados, construção das diferentes modelagens da rede, análises topológicas, detecção de comunidades, validação biológica e geração das figuras e tabelas apresentadas neste relatório.

Também estão disponíveis os resultados completos dos experimentos, arquivos auxiliares, tabelas, imagens e visualizações interativas produzidas com a biblioteca Plotly, permitindo explorar tridimensionalmente as redes modeladas e os resultados obtidos.

Os notebooks foram organizados e numerados de acordo com a sequência em que o projeto foi desenvolvido, permitindo acompanhar de forma cronológica a evolução da metodologia, os testes realizados, as decisões de modelagem e a consolidação da solução final adotada.

O repositório pode ser acessado em: <https://github.com/amaurywalbert/redes-complexas-projeto/>

Referências

COSCIA, Michele. The Atlas for the Aspiring Network Scientist. Lulu Press, 2021. Disponível em: <https://asmithh.github.io/network-science-data-book/>. Acesso em: 23 jun. 2026.

ROSVALL, Martin; BERGSTROM, Carl T. Maps of random walks on complex networks reveal community structure. Proceedings of the National Academy of Sciences, v. 105, n. 4, p. 1118–1123, 2008. DOI: <https://doi.org/10.1073/pnas.0706851105>.

RCSB PROTEIN DATA BANK. RCSB PDB: Protein Data Bank. Disponível em: <https://www.rcsb.org/>. Acesso em: 21 jun. 2026.

RCSB PROTEIN DATA BANK. Structure of Human Adenovirus 5. PDB ID: 6B1T. Disponível em: <https://www.rcsb.org/structure/6B1T>. Acesso em: 21 jun. 2026.

RCSB PROTEIN DATA BANK. Annexin V Crystal Structure. PDB ID: 1A3N. Disponível em: <https://www.rcsb.org/structure/1A3N>. Acesso em: 24 jun. 2026.